



**DEPARTAMENTO
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico 3

Algoritmos en sistemas distribuidos

13 de noviembre de 2014

Sistemas Operativos

Integrante	LU	Correo electrónico
Rodriguez, Pedro	197/12	pedro3110.jim@gmail.com
Benegas, Gonzalo Segundo	958/12	gsbenegas@gmail.com
Barrios, Leandro Ezequiel	404/11	ezequiel.barrios@gmail.com



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359

<http://www.fcen.uba.ar>

Introducción

Hoy en día, la globalización y creciente utilización mundial masiva de medios de información como la internet, ha impulsado la existencia de gigantes de la información. Ejemplos de estos son empresas como Facebook, Yahoo!, Google, Twitter y otros. La mayor parte del servicio provisto por estas empresas a sus usuarios, consiste y necesita de la utilización, procesamiento y análisis de grandes bases de datos. Por ello, una de las más frecuentes acciones que deben ser efectuadas es el filtrado de datos y su posterior procesamiento.

Un método comúnmente utilizado dentro del entorno de procesamiento de datos a través de clusters es el **MapReduce**, creado por la empresa Google. Este permite analizar un gran conjunto de datos, relacionándolos a través de un índice (*key*) a través de una operación **map**, para luego operar sobre los conjuntos de valores asociados a cada *key* a través de una operación **reduce**. Opcionalmente, es posible aplicar al conjunto de datos producido por **reduce**, una última operación **finalize**.

Considerando la inmensidad del volumen de información con el que se trabaja, y el gran costo económico que implican la fabricación y el funcionamiento de los servidores adecuados para manipularla, es importante lograr el máximo aprovechamiento de los recursos computacionales de los que estas empresas disponen. Por ello, se intenta trabajar con la máxima eficiencia algorítmica, temporal y de espacio posibles.

Contents

1	Implementación de Map-Reduce	1
1.1	Encontrar el subreddit con mayor score promedio	1
1.2	Encontrar los doce títulos con mayor score de la colección de posts con al menos 2000 votos.	2
1.3	Para los diez mejores scores, calcular la cantidad de comentarios en promedio por sumisión.	3
1.4	Entre los usuarios con a la sumo 5 sumisiones, encontrar el que posea mayor cantidad de upvotes.	4
1.5	Para todos los subreddit que poseen un score entre 280 y 300, indicar la cantidad palabras presentes nnen sus títulos	5
2	Investigación	6
2.1	Explique cuál es el entorno y la situación donde se plantea el problema. (Motivación)	7
2.2	Identifique el problema	8
2.2.1	Localidad de Datos:	8
2.2.2	Interdependencia:	8
2.3	Identifique situaciones donde el problema se dispara y la consecuencias que esto genera.	9
2.4	Comente el background histórico del problema	10
2.5	Explique otros problemas asociados a la búsqueda de una mejor solución	11
2.5.1	Head-of-line scheduling	11
2.5.2	Sticky Slots	11
2.5.3	Reduce Slot Hoarding:	12
2.5.4	Uso de Espacio en Disco:	12
2.6	Explique las soluciones propuestas	13
2.6.1	Delay Scheduling:	13
2.6.2	Copy-Compute Splitting:	13
2.7	Evalúe soluciones propuestas	14
2.8	Discusión	15
2.9	Conclusiones	16

Parte I Implementación de Map-Reduce

1.1 Encontrar el subreddit con mayor score promedio

Figure 1.1.1: La función `map`

```
function () {  
    emit(this.subreddit, { count: 1, sum: this.score } );  
}
```

La función *map* se aplica a cada post y emite, con el *subreddit* como key, una tupla con la cantidad de posts - inicializada en 1 - y la suma de los scores – inicializada con el score del post.

Figure 1.1.2: La función `reduce`

```
function (key, values) {  
    reducedVal = {count: 0, sum: 0};  
    for (var i = 0; i < values.length; i++) {  
        reducedVal.count += values[i].count;  
        reducedVal.sum += values[i].sum;  
    };  
    return reducedVal;  
}
```

Tras aplicar la función *map* quedan asociados cada subreddit con una lista de las tuplas asociados a los posts del subreddit. La función *reduce* toma un fragmento de esta lista y la reduce en una sola tupla que acumula la cantidad de posts y la suma de los scores.

Figure 1.1.3: La función `finalize`

```
function finalize (key, reducedVal) {  
    return reducedVal.sum / reducedVal.count;  
}
```

Luego de la etapa de *reduce*, quedan asociados cada subreddit con su cantidad de posts y su suma de scores. La función *finalize* calcula el promedio final realizando una división.

Ejecutamos el query y utilizamos la función `sort` en la consola de Mongo. El subreddit *GirlGamers* tiene el mayor score promedio: 2483.

1.2 Encontrar los doce títulos con mayor score de la colección de posts con al menos 2000 votos.

Figure 1.2.4: La función map

```
function () {  
  if (this.total_votes >= 2000)  
    emit(this.title, this.total_votes);  
}
```

Se emiten, para todos los posts con al menos 2000 votos, su título y su cantidad de votos.

Figure 1.2.5: La función reduce

```
function (key, values) {  
  return Array.sum(values);  
}
```

Para cada título, se suman los votos de sus posts.

Tras ejecutar el query, se ordenaron los resultados. Los doce títulos con mayor score de la colección de posts con al menos 2000 votos son:

Título	Score
"Airline screwed up, a friend just posted this on Facebook."	177103
"Following the Obama AMA"	144145
"Nailed it."	129307
"Help a brother out!"	129183
"Seen in NJ, what a friendly neighbor"	126222
"McKayla Maroney visits the White House... her picture with the President"	120929
"The Bus Knight"	119774
"Brilliant and thoughtful parents handed these out to everyone on my flight."	119232
"Screenshot of reddit from the year 3012"	118866
"Standing guard, hurricane or otherwise"	117272
"My neighbors are taking this especially hard."	117101
"When I found out I could upvote by pressing 'A'"	115717

1.3 Para los diez mejores scores, calcular la cantidad de comentarios en promedio por sumisión.

Este ejercicio se resuelve de manera análoga al ejercicio 1.

Figure 1.3.6: La función map

```
function () {  
    emit(this.score, {count: 1, sum: this.number_of_comments});  
}
```

Figure 1.3.7: La función reduce

```
function (key, values) {  
    reducedVal = {count: 0, sum: 0};  
    for (var i = 0; i < values.length; i++) {  
        reducedVal.count += values[i].count;  
        reducedVal.sum += values[i].sum;  
    };  
    return reducedVal;  
}
```

Figure 1.3.8: La función finalize

```
function finalize (key, reducedVal) {  
    return reducedVal.sum / reducedVal.count;  
}
```

Los resultados se ordenaron. Los diez mejores scores y la cantidad de comentarios en promedio por sumisión son:

Score	Comentarios en promedio
20570	1463
12333	1612
11908	2681
10262	1514
8935	480
8835	1716
8699	934
8241	571
7297	1110
6741	2204

1.4 Entre los usuarios con a la sumo 5 sumisiones, encontrar el que posea mayor cantidad de upvotes.

Este ejercicio se resuelve de forma similar al ejercicio 1, salvo que en la función *finalize* se filtran los usuarios con más de 5 sumisiones.

Figure 1.4.9: La función `map`

```
function () {  
    emit(this.username, {sumisiones: 1, number_of_upvotes: this.number_of_upvotes});  
}
```

Figure 1.4.10: La función `reduce`

```
function (key, values) {  
    var res = {sumisiones: 0, number_of_upvotes: 0};  
    for (var i = 0; i < values.length; i++) {  
        var val = values[i];  
        res.sumisiones += val.sumisiones;  
        res.number_of_upvotes += val.number_of_upvotes;  
    }  
    return res;  
}
```

Figure 1.4.11: La función `finalize`

```
function finalize (key, reducedVal) {  
    if (reducedVal.sumisiones <= 5)  
        return reducedVal.number_of_upvotes;  
}
```

Los resultados se ordenaron. El usuario con a lo sumo cinco sumisiones ya la mayor cantidad de upvotes es “lepry”, con 90396 upvotes.

1.5 Para todos los subreddit que poseen un score entre 280 y 300, indicar la cantidad palabras presentes nnen sus títulos

Este ejercicio se resuelve de forma similar al ejercicio 1, salvo que en la función *finalize* se filtran los subreddit cuyo score no se encuentra en el intervalo [280,300].

Figure 1.5.12: La función map

```
function () {  
    var cantPalabras = this.title.split(' ').length;  
    emit(this.subreddit, {score: this.score, cantPalabras: cantPalabras});  
}
```

Figure 1.5.13: La función reduce

```
function (key, values) {  
    var res = {score: 0, cantPalabras: 0};  
    for (var i = 0; i < values.length; i++) {  
        var val = values[i];  
        res.score += val.score;  
        res.cantPalabras += val.cantPalabras;  
    }  
    return res;  
}
```

Figure 1.5.14: La función finalize

```
function finalize (key, reducedVal) {  
    if (280 <= reducedVal.score && reducedVal.score <= 300)  
        return reducedVal.cantPalabras;  
}
```

Los únicos resultados arrojados fueron:

Subreddit	Palabras en títulos
“Firearms”	24
“anime”	18
“Sexy”	13
“Feminism”	6
“HeroesofNewerth”	6
“TheRealZachAnner”	4
“ragecomics”	4
“xkcd”	4

Parte II Investigación

Para esta parte del TP se pide leer e interpretar el paper «**Job Scheduling for Multi- User MapReduce Clusters**»¹. Se sugiere además una serie de puntos para analizar el contenido del paper. Estos son los siguientes:

- 2.1 Explique cuál es el entorno y la situación donde se plantea el problema. (Motivación)
- 2.2 Identifique de problema
- 2.3 Identifique situaciones donde el problema se dispara y la consecuencias que esto genera.
- 2.4 Comente el background histórico del problema
- 2.5 Explique otros problemas asociados a la búsqueda de una mejor solución
- 2.6 Explique las soluciones propuestas
- 2.7 Evalúe soluciones propuestas
- 2.8 Discusión
- 2.9 Conclusiones

¹http://www.icsi.berkeley.edu/pubs/techreports/ICSI_jobschedulingfor09.pdf

2.1 Explique cuál es el entorno y la situación donde se plantea el problema. (Motivación)

La idea tras este paper surgió luego de que los autores se vieran frente a la tarea de diseñar un scheduler para MapReduce, para la empresa Facebook. Este sería el encargado de repartir el poder de cómputo en un *warehouse Hadoop*² de 600 nodos, en un entorno multiusuario, en donde se combinarían tareas de producción con tareas experimentales.

Este warehouse era utilizado para aproximadamente 3200 operaciones de MapReduce diarias, siendo que algunas de ellas eran tareas frecuentes de mantenimiento, análisis de datos, antispam y optimización, cuya ejecución se prolongaba a lo largo de horas, mientras que otras eran queries *AD-HOC* cuya ejecución demoraba unos pocos minutos. Por tal motivo, era de vital importancia poder lograr un mecanismo de **scheduling justo**.

²Hadoop es la versión *open-source* de MapReduce.

2.2 Identifique el problema

Se describen principalmente dos aspectos en donde el scheduling de un cluster MapReduce se diferencia de un mecanismo genérico de scheduling, y por los cuales el mecanismo de scheduling utilizado previamente presentaba una pérdida de rendimiento de entre 2 y 10 veces en comparación con el mecanismo presentado en el paper. Los dos principales aspectos problemáticos fueron la *localidad de datos*, y la *interdependencia entre las operaciones Map y Reduce*.

2.2.1 Localidad de Datos:

Este problema comprende la necesidad inherente de la técnica MapReduce de tener acceso local a los datos con los cuales se están trabajando. Esta necesidad se debe principalmente a que a diferencia de los algoritmos “CPU- INTENSIVE”³, el MapReduce entra en la categoría de los denominados “DATA-INTENSIVE”, es decir, aquellos en donde el poder de cómputo necesario es despreciable frente a la gran cantidad de datos con los que se trabaja.

Desde esta perspectiva, contar con un scheduler eficiente en el acceso y la utilización de los datos, es mucho más importante que en otro tipo de situaciones. Todo esto está agravado por el costo que supone el almacenamiento, y la transmisión de datos entre distintos servidores. Este defecto se puede observar principalmente en **trabajos pequeños y/o concurrentes**.

2.2.2 Interdependencia:

Se entiende por interdependencia a la necesidad de que todas las tareas de **map** se encuentren finalizadas al momento de iniciar la ejecución de **reduce**. Es fácil percibir la gran cantidad de inconvenientes que esto genera. Se mencionan particularmente los casos de **infrautilización de los recursos y starvation**, en donde se da que una única tarea adquiere cierta cantidad de slots, destinados a realizar la operación **reduce**, pero que se ven bloqueados/inutilizados hasta el momento en que esta tarea termine de realizar su operación de **map**, evitando de esta forma que otras tareas se ejecuten, y de **consumo excesivo de espacio de disco** destinado a los datos intermedios producidos por **map** (datos que no pueden ser liberados hasta que el trabajo termine).

³Los que necesitan un gran poder de cómputo.

2.3 Identifique situaciones donde el problema se dispara y la consecuencias que esto genera.

Los problemas descritos anteriormente se ponían en evidencia al momento de querer realizar queries **ad-hoc** de muy corta duración frente a los trabajos de producción que el warehouse debe correr periódicamente. Bajo esta perspectiva, era deseable que los trabajos experimentales puedan ser lanzados en cualquier momento, y tener un tiempo de respuesta **acceptable**. Con la implementación del Scheduler FIFO de Hadoop, esto se volvía imposible, reduciendo significativamente la utilidad del sistema.

2.4 Comente el background histórico del problema

Hadoop está inspirado en el MapReduce de Google, por lo que gran parte de su implementación básica está fuertemente ligada a este proyecto. La primer solución al conflicto del scheduling, se encuentra provista por defecto dentro la propia implementación de Hadoop, y consta de una cola **FIFO** de 5 niveles de prioridad, de forma tal que cada vez que un slot se libera, el scheduler lo asigna a la más prioritaria de entre las tareas pendientes.

Sobre este enfoque, Hadoop aplica una **optimización de localidad**, al igual que lo hace MapReduce de Google: dado que una tarea generalmente consta de múltiples operaciones de **map**, luego de elegir una tarea el scheduler selecciona las operaciones map más adecuadas según un **criterio de localidad**. Serán elegidos entonces los maps que utilicen datos que se encuentren más cerca físicamente al worker que está corriendo la tarea. Es decir, serán elegidas primero las que se encuentren en ese mismo worker, luego las que se encuentren en el mismo rack, y finalmente las que se encuentren en racks remotos.

La gran desventaja del scheduler **FIFO** es el pésimo tiempo de respuesta para trabajos pequeños cuando se encuentran intercalados con trabajos grandes. Por ello, la primer solución que se implementó, es el mecanismo denominado **Hadoop On Demand (HOD)**. Sin embargo, este mecanismo también ocasionó problemas, principalmente **baja localidad de los datos** y **baja utilización de los recursos**,

2.5 Explique otros problemas asociados a la búsqueda de una mejor solución

Para explicar el problema, es necesario ahondar un poco en los conceptos utilizados en el paper. Se describe un **job** como un conjunto de **tasks**, siendo un task una operación **map-reduce**. Cada nodo (también llamados **slaves** o **workers**) tiene una determinada cantidad de **slots de ejecución**, y conforme estos se van liberando el Scheduler le va asignando **tasks**, siendo que cada uno de estos ocupa un **slot**.

Problemas asociados a la Localidad de Datos

2.5.1 Head-of-line scheduling

:

Para explicar este concepto, el paper propone una métrica, **el porcentaje de localidad⁴ de un job en relación a su tamaño**. Utilizando esta métrica, dado un **job**, su porcentaje de localidad se ve representado por la cantidad de **nodos** en la que se encuentran distribuidos los datos de sus **tasks**, en relación al total. Se hace notar que el **porcentaje de localidad de un job** crece en relación a su tamaño (medido en cantidad de **tasks**), de forma tal que un **job** pequeño tiene mucha menos **localidad** que un **job** grande. Por otro lado, dado que se utiliza una cola **FIFO**, el siguiente **job** a ejecutar se encuentra de cierta forma *predeterminado*, por lo que no es posible “elegir el más apropiado”.

Así, dado un **nodo** cualquiera al que se le hayan liberado uno o más **slots**, la probabilidad de que el siguiente **job** contenga un **task** cuyos datos se encuentren en ese **nodo**, es proporcional al tamaño del **job**. Y esto ocasiona problemas en los **jobs** pequeños, los cuales suelen ser justamente los que más necesidad de **interactividad** tienen.

2.5.2 Sticky Slots

:

Este problema puede aparecer incluso con **jobs** de tamaño grande. Se puede entender con el siguiente ejemplo: Tenemos 10 **jobs** con 10 **tasks** corriendo cada uno. En cuanto un **job** termina un **task**, se debe determinar a quién asignar el **slot** libre. Como este mismo **job** tiene 9 **tasks** corriendo, y el resto 10, según el **fair scheduling** se le asignaría este **slot** al mismo que lo liberó. Como consecuencia de este comportamiento, los **jobs** difícilmente abandonan sus **slots** originales. Entonces, si inicialmente este tenía baja **localidad**, la sigue manteniendo hasta el final.

Problemas asociados a la Interdependencia de Map-Reduce

⁴En el paper se distingue entre localidad de nodo y localidad de rack; la idea sigue siendo la misma.

2.5.3 Reduce Slot Hoarding:

Este problema está relacionado con la operación de **Reduce**. Para entenderlo, es necesario recordar brevemente qué es lo que hace una operación **Reduce**. Se compone básicamente de dos partes: Durante la primera fase, en donde predomina la característica antes presentada como **DATA-INTENSIVE**⁵, se copian los datos emitidos por la función **Map**. Luego, en una segunda fase, caracterizada por ser **CPU-INTENSIVE**⁶, se los procesan.

También vale la pena mencionar que en el paper se hace distinción entre **Slot de Map** y **Slot de Reduce**, y que estos últimos se liberan sólo cuando el **job** termina.

Todo esto ocasiona principalmente dos complicaciones. Primero, una mala utilización de los **slots**: cuando un **job** se compone de miles de **tasks**, los **map** se van ejecutando a medida que se van liberando **slots de Map** en los **nodos**. Así, se va produciendo el output necesario para ser utilizado por **Reduce**. De esta forma, se comienzan a reservar slots para **Reduce**, los cuales serán “brevemente” utilizados para procesar los output de los **map** (se procesa un output por slot), y luego quedarán bloqueados hasta el momento en que el **job** finalice.

La segunda complicación tiene que ver con la mala administración de los recursos dentro de la misma operación de **Reduce**. Dado que la operación se compone de dos partes, en donde una hace un uso intensivo de los recursos de entrada/salida, y la otra hace un uso intensivo de la CPU, y que estos se producen en forma secuencial. Es fácil ver que en todo momento, en cada slot de **Reduce**, aun asumiendo una buena utilización desde el punto de vista del Scheduling, se va a estar realizando una operación de, o **Input/Output**, o **CPU**, una por vez, cuando en un escenario más eficiente se podrían estar utilizando ambas cosas a la vez.

2.5.4 Uso de Espacio en Disco:

Relacionado al problema descripto anteriormente, existe también un inconveniente que se presenta al acaparar muchos **slots de Reduce** para un **job**. Dado que el **Reduce** utiliza y produce **datos intermedios**, que son guardados en el disco, y que no son liberados hasta que todo el **job** termina, esto puede llevar a producir un **acaparamiento de disco**. En el peor caso, por ejemplo cuando hubiese muchos **jobs** corriendo al mismo tiempo, este se podría llenar, y para solucionar habría que descartar todos los datos de uno o varios **jobs**.

⁵Alta tasa de uso de Input/Output.

⁶Alta tasa de uso de CPU.

2.6 Explique las soluciones propuestas

Para solucionar todos los inconvenientes descritos, el paper propone un mecanismo de Scheduling que autodenominan FAIR. Este mecanismo está ideado para cumplir principalmente con dos características:

- **Aislamiento:** brindarle a cada usuario la ilusión de estar corriendo un cluster privado.
- **Multiplexado Estadístico:** redistribuir en tiempo de ejecución los recursos no utilizados.

Para lograr estos objetivos, se implementaron dos mecanismos:

2.6.1 Delay Scheduling:

para solucionar los **problemas de localidad de datos**. Para ello, cuando un **job** se encuentra en condiciones de que le sean asignados **slots**, el Scheduler se fija si este contiene **tasks** aptas para correr localmente en alguno de los **nodos** que tienen **slots disponibles**. En el caso en que esto no suceda, se lo saltea hasta encontrar algún **job** que contenta **tasks** apropiados. Para evitar **starvation**, se implementa un mecanismo de **timeout** mediante el cual, luego de transcurrido ese tiempo sin que le sean asignados **slots libres**, a un **job** se le permite correr tareas, aun cuando estas sean en forma no-local.

2.6.2 Copy-Compute Splitting:

para solucionar los **problemas de interdependencia**. Se propone dividir la operación de **Reduce** en dos tipos de **tareas independientes**, tareas de copia y tareas de cómputo. Para ello es posible dividir las tareas en dos procesos separados, pero esto traería muchas complicaciones desde el punto de vista del aislamiento de los procesos, ya que sería necesario en tal caso implementar un complejo mecanismo de **memoria compartida**. Se propone en cambio una solución que denominan CPAC (**Compute Phase Admission Control**), que básicamente se trata de reservar una cantidad de **slots de Reduce** mayor a la que el sistema soporta, llevando cuenta en todo momento de cuántos de estos están realizando operaciones de copia y cuántos están realizando cómputo. Asimismo, se limita la cantidad de slots que tienen permiso de copia y permiso de cómputo. Así, cada vez que una operación de **Reduce** requiere hacer copia o cómputo, primero le pide permiso al Scheduler. Así, se busca asegurar que, siendo N_{min} la cantidad de slots de Reduce que soporta el nodo en cuestión, en todo momento haya a lo sumo N_{min} operaciones de copia y N_{min} operaciones de cómputo corriendo concurrentemente.

2.7 Evalúe soluciones propuestas

Se evaluaron los algoritmos en un caso de benchmark grande, del tamaño de las tareas de producción en Facebook. El entorno principal de evaluación fue Amazon's Elastic Compute Cloud⁷.

Se pudo ver que el fair sharing disminuye a la mitad el tiempo de respuesta promedio comparado con FIFO en jobs pequeños, a expensas de un pequeño aumento frente a jobs grandes. Sin embargo, algunos jobs todavía eran demorados por el *reduce slot hoarding*. Al introducir el copy-compute splitting, el fair sharing obtuvo una mejora de hasta 4.6x en jobs pequeños.

El *delay scheduling* permitió pasar de un porcentaje previo de localidad de 27-90% a un asombroso nivel de 99-100%. Para una cantidad de 50 tareas concurrentes, aumentó el throughput por un factor de 2.0. Por otra parte, el tiempo de respuesta no presentó mejoras significativas.

⁷<http://aws.amazon.com/ec2/>

2.8 Discusión

El trabajo desarrollado en el paper consiste en encontrar un punto intermedio óptimo entre tener un cluster separado para cada usuario (que provee gran aislamiento pero una pobre utilización) y tener un único cluster FIFO (que provee gran utilización pero ningún tipo de aislamiento entre usuarios).

Se identificaron dos aspectos en el manejo de un cluster de datos intensivo que generan problemas: localidad de datos e interdependencia entre tareas. A pesar de que hasta aquí todo giró en torno a MapReduce, estos problemas son importantes en cualquier cluster de cómputos que utilice grafos dirigidos aciclicos de procesos para efectuar cómputos, ya que este tipo de sistema necesita colocar tareas en nodos que contienen sus inputs, y así correr el riesgo de encontrarse con problemas de los cuales ya hablamos, como por ejemplo `sticky slot` y `head-of-line scheduling`.

2.9 Conclusiones

A pesar de que MapReduce ha sido un modelo de ejecución muy popular y exitoso para largos **batch jobs**, muchas empresas han comenzado a compartir sus clusters de MapReduce entre múltiples usuarios, corriendo así una mezcla de trabajos **batch** e **interactivos**. En el paper se propone FAIR, un scheduler justo que permite aislamiento entre usuarios, bajo tiempo de respuesta y alto **throughput**. Para lidiar con los problemas que este scheduling genera (localidad de datos e interdependencia entre tareas), se pueden emplear dos técnicas simples y robustas: delay scheduling y copy-compute splitting.